

R E I A PARA LA ENSEÑANZA DEL ANÁLISIS DE DATOS

NOTAS COMPLEMENTARIAS

INDER TECUAPETLA


1. BOXPLOT

Un boxplot está compuesto por:

- **Caja (box):** representa el rango intercuartílico (IQR), es decir, el 50 % central de los datos (del cuartil 1 al cuartil 3).
- **Línea dentro de la caja:** es la mediana (el valor central).
- **Bigotes (whiskers):** se extienden hasta los valores más extremos que aún se consideran “normales” (generalmente hasta $1.5 \times \text{IQR}$ desde los cuartiles).
- **Puntos fuera de los bigotes:** son los valores atípicos (outliers).

```
datos <- data.frame(temp = c(15,16,16,17,17,18,18,19,20,28))

ggplot(datos, aes(x = "", y = temp)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Ejemplo de boxplot con outlier",
       y = "Temperatura (°C)") +
  theme_minimal()
```



En este ejemplo tenemos:

- Mediana (Q2): valor central $\rightarrow 17.5$
- Q1 (25 %): 16.5

- Q3 (75 %): 18.5
- IQR (Q3 – Q1): 2
- Bigotes:
 - Límite inferior: $Q1 - 1.5 \times IQR = 16.5 - 3 = 13.5$
 - Límite superior: $Q3 + 1.5 \times IQR = 18.5 + 3 = 21.5$
 - Todo lo que esté fuera de 13.5–21.5 se considera outlier; el valor 28 está fuera de rango por tanto es un **outlier**.

En el bottle dataset de CalCOFI tenemos el siguiente boxplot:

```
calcofi_oceanica <- calcofi %>% filter(Dist_cat == "Oceánica")

ggplot(calcofi_oceanica, aes(x = Dist_cat, y = mean_T_degC, fill = Dist_cat)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Temperatura en categoría Oceánica (outliers marcados)",
       x = "", y = "Temperatura (°C)") +
  theme_minimal()
```




FIGURA 1. Distribución de la temperatura del océano registrada en puntos a distancia Oceánica respecto de la línea de costa.

con las siguientes estadísticas asociadas:

```
summary(calcofi_oceanica$mean_T_degC)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   6.313  10.100  12.033  12.390  14.374  34.322
```

por lo que el IQR en este caso es 4.274. De este modo, los límites inferior y superior son 3.689 y 20.785, respectivamente. Así todo valor fuera de este rango se considerará un outlier.

2. CORRELACIÓN

La correlación mide cómo dos variables se mueven juntas. Si incrementos en una variable tienden a acompañarse de incrementos en otra, hablamos de correlación positiva; si incrementos en una se asocian con disminuciones en otra, es negativa. Véase Lee Rodgers and Nicewander (1988) para diferentes representaciones del mismo objeto estadístico.

Coeficiente de correlación:

- Rango: De -1 a 1.
- Relación (lineal) positiva perfecta: 1
- Relación (lineal) negativa perfecta: -1
- No hay relación lineal: 0

Tipos principales:

- Pearson (r): para variables continuas con relación lineal.
- Spearman (ρ): para datos ordinales o rangos.
- Point-biserial y Phi: para variables dicotómicas.

Precauciones:

- Correlación no es equivalente a causalidad: Dos variables pueden estar correlacionadas por un tercer factor (ej. clima afecta tanto temperatura como oxígeno).
- Distorsiones comunes:
 - Restricción de rango: reduce artificialmente la magnitud de la correlación.
 - Datos atípicos: pueden inflar o reducir la correlación.
 - Muestras pequeñas: generan coeficientes poco estables.

El siguiente ejemplo muestra datos sintéticos de temperatura y oxígeno


```
temp <- c(15,16,17,18,19,20)
ox    <- c(8.0,7.8,7.5,7.2,6.9,6.5)

cor(temp, ox, method = "pearson")
```

```
## [1] -0.9957939
```

La representación gráfica de la asociación entre estas variables es:

```
plot(temp, ox,
      main = "Relación entre temperatura y oxígeno",
      xlab = "Temperatura (°C)", ylab = "Oxígeno (ml/L)",
      pch = 19, col = "blue")
abline(lm(ox ~ temp), col = "red")
```



Por completitud incluimos definiciones formales del coeficiente de correlación.

2.1. Definición teórica (poblacional). Sea (X, Y) un par de variables aleatorias con medias μ_X , μ_Y y desviaciones estándar σ_X , σ_Y , respectivamente. La correlación **poblacional** se define como:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

donde

$$\text{Cov}(X, Y) = \mathbf{E}[(X - \mu_X)(Y - \mu_Y)].$$

Es decir, la correlación es la covarianza normalizada por las desviaciones estándar.

2.2. Definición muestral (estimador). Dado un conjunto de observaciones (x_i, y_i) , con $i = 1, \dots, n$, la correlación muestral de Pearson se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde $\bar{x}$, $\bar{y}$ son las medias muestrales de X e Y , respectivamente.

3. INTERVALO DE CONFIANZA PARA LA MEDIA

Un intervalo de confianza (IC) es un rango de valores calculado a partir de una muestra que, con cierta probabilidad (nivel de confianza), contiene el verdadero valor del parámetro poblacional, Casella and Berger (2002), Wasserman (2004).

Por definición, un IC para la media poblacional μ se construye como: Sea una muestra aleatoria $X_1, X_2, \dots, X_n$ de una población con media μ y varianza σ^2 . La media muestral es:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Si la población es normal o n es suficientemente grande, un intervalo de confianza $(1 - \alpha)$ para la media μ se construye como:

$$IC_{(1-\alpha)} : \quad \bar{X} \pm t_{1-\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}},$$

donde s es la desviación estándar muestral y $t_{1-\alpha/2, n-1}$ es el valor crítico de la distribución t de Student con $n - 1$ grados de libertad.

- El nivel de confianza más usado es 95 %, aunque también se emplean 90 % o 99 %.
- El IC refleja la incertidumbre inherente al muestreo: no garantiza que el parámetro esté dentro del intervalo, sino que en repeticiones del procedimiento, el porcentaje especificado de intervalos incluiría el valor verdadero.

Fundamentos teóricos

Frecuentista: El IC se interpreta en términos de repeticiones hipotéticas del muestreo.

Bayesiano: Se habla de intervalos de credibilidad, que tienen una interpretación probabilística directa sobre el parámetro.

Elementos clave:

- Estimador puntual ($\bar{x}$, proporción, etc.).
- Error estándar del estimador.
- Valor crítico de la distribución (t -Student, normal estándar, etc.).
- Margen de error = valor crítico $\times$ error estándar.

Algunas propiedades

- Precisión: Intervalos más estrechos indican mayor precisión.
- Dependencia del tamaño de muestra: A mayor n , menor error estándar y más estrecho el IC.
- Supuestos: Normalidad de los datos (o del estimador, vía teorema central del límite), independencia de observaciones.
- Limitaciones: En muestras grandes, cualquier desviación de normalidad puede invalidar el IC clásico; en distribuciones sesgadas, conviene usar bootstrap o transformaciones, Dikta and Scheer (2022).

Comentarios finales

La probabilidad se refiere a la incertidumbre antes de observar los datos: por ejemplo, la probabilidad de que una variable aleatoria tome cierto valor. En cambio, la confianza en un intervalo se interpreta en términos de un procedimiento repetido: si construimos intervalos de confianza al 95 % a partir

de muchas muestras distintas, aproximadamente el 95 % de esos intervalos contendrán el verdadero valor de la media poblacional. Una vez que el intervalo está calculado con los datos observados, no tiene sentido hablar de “probabilidad de que la media esté dentro del intervalo”, porque la media es fija y el intervalo ya está determinado. Lo correcto es decir que el intervalo se construyó mediante un procedimiento que, en el largo plazo, captura el parámetro verdadero en el porcentaje especificado de casos.

4. ¿QUÉ ES UNA PRUEBA DE HIPÓTESIS?

Una prueba de hipótesis es un procedimiento estadístico que nos permite evaluar si la evidencia en una muestra es consistente con una afirmación sobre la población.

- Hipótesis nula (H_0): representa la condición de referencia, estabilidad o ausencia de efecto.
- Hipótesis alternativa (H_1): representa el cambio, diferencia o efecto que queremos detectar.

4.1. Elementos clave.

- Planteamiento de la hipótesis:
 - Ejemplo ambiental: La concentración promedio de nitratos en las aguas monitoreadas por CalCOFI se encuentra por debajo del umbral de preocupación ambiental de $16 \mu\text{M}$
 - H_0 = “Promedio de nitratos es igual a $16 \mu\text{M}$ ”.
 - H_1 = “Promedio de nitratos es menor a $16 \mu\text{M}$ ”.
- Estadístico de prueba: Se calcula a partir de los datos (ej. t -estadístico). Resume la evidencia contra H_0 .
 - Ejemplo ambiental: Suponiendo que las observaciones de nitratos son independientes y aproximadamente normales con media μ y desviación estándar σ , entonces se sabe que

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

por tanto

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Sin embargo, no conocemos el valor de σ , por lo que usamos la desviación estándar muestral s y el estadístico de prueba se convierte en

$$t = \frac{\bar{X}_n - \mu}{s/\sqrt{n}}$$

- Distribución de referencia: **Bajo H_0** , el estadístico sigue una distribución conocida (ej. t -Student). Esto permite calcular probabilidades.
 - Ejemplo ambiental: Si H_0 es cierta, entonces el estadístico t sigue una distribución t -Student con $n - 1$ grados de libertad.
- p -valor: **Probabilidad** de obtener un resultado tan extremo como el observado, si H_0 fuera cierta. Si es pequeño (ej. < 0.05), se considera evidencia contra H_0 .
 - Ejemplo ambiental: En este caso, nos interesa calcular la probabilidad de observar un valor de t tan bajo como el calculado, dado que la media poblacional es $16 \mu\text{M}$. Si este p -valor es menor a 0.05 , rechazamos H_0 . Es decir, necesitamos calcular

$$p = P(t \leq t_{\text{obs}} \mid H_0),$$

donde t_{obs} es el valor calculado del estadístico de prueba.

■ Decisión:

- Rechazar $H_0 \rightarrow$ hay evidencia de que el promedio de nitratos es menor que el valor nominal ($16 \mu\text{M}$).
- No rechazar $H_0 \rightarrow$ no hay evidencia suficiente para afirmar que el promedio de nitratos es menor que el valor nominal ($16 \mu\text{M}$).

5. PRUEBAS DE HIPÓTESIS EN CONTEXTO AMBIENTAL

Una prueba de hipótesis no es solo un cálculo mecánico: debe estar anclada en una pregunta científica o ambiental. En lugar de comparar contra un valor arbitrario (ej. $2 \text{ mg}/\text{m}^3$), podemos formular hipótesis basadas en condiciones ecológicas, estacionales o espaciales.

5.1. Ejemplos de hipótesis contextualizadas.

■ Hipótesis espacial:

- H_0 : La media de nitratos en zona superficial es igual a la media en zona profunda.
- H_1 : La media de nitratos en zona superficial difiere de la media en zona profunda (posible efecto de surgencias).

En este caso el estadístico de prueba podría ser un t -test para muestras independientes, comparando las medias de nitratos en ambas zonas. Más específicamente, si $X_1, X_2, \dots, X_n$ son las concentraciones de nitratos en la zona superficial y $Y_1, Y_2, \dots, Y_m$ en la zona profunda, entonces el estadístico sería:

$$t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}}$$

y se sabe que los grados de libertad aproximados se calculan mediante la fórmula de Welch-Satterthwaite:

$$df \approx \frac{\left(\frac{s_X^2}{n} + \frac{s_Y^2}{m}\right)^2}{\frac{(s_X^2/n)^2}{n-1} + \frac{(s_Y^2/m)^2}{m-1}}.$$

Operativamente, tenemos:

```
# Extraer los datos por zona de profundidad
nitrate_surface <- calcofi %>%
  filter(Depth_zone == "Surface") %>%
  pull(mean_Nitrate)

nitrate_deep <- calcofi %>%
  filter(Depth_zone == "Deep") %>%
  pull(mean_Nitrate)
```

```

mean_surface <- mean(nitrate_surface, na.rm = TRUE)
mean_deep    <- mean(nitrate_deep, na.rm = TRUE)

sd_surface <- sd(nitrate_surface, na.rm = TRUE)
sd_deep    <- sd(nitrate_deep, na.rm = TRUE)

n_surface <- length(na.omit(nitrate_surface))
n_deep    <- length(na.omit(nitrate_deep))

se <- sqrt( (sd_surface^2 / n_surface) + (sd_deep^2 / n_deep) )

t_stat <- (mean_surface - mean_deep) / se

df <- ( (sd_surface^2/n_surface + sd_deep^2/n_deep)^2 ) /
      ( ((sd_surface^2/n_surface)^2 / (n_surface-1)) +
        ((sd_deep^2/n_deep)^2 / (n_deep-1)) )

p_val <- 2 * (1 - pt(abs(t_stat), df))

list(
  mean_surface = mean_surface,
  mean_deep    = mean_deep,
  t_statistic  = t_stat,
  df           = df,
  p_value      = p_val
)

# Two-sample t-test (bilateral)
resultado <- t.test(nitrate_surface, nitrate_deep, alternative = "two.sided")

# Mostrar el p-value directamente
resultado$p.value

```

■ Hipótesis estacional:

- H_0 : La media de clorofila en Quarter 2 es igual a la de Quarter 1.
- H_1 : La media de clorofila en Quarter 2 es mayor (esperando un pico de productividad en primavera).

```

chl_q1 <- calcofi %>% filter(Quarter == 1) %>% pull(mean_ChlorA)
chl_q2 <- calcofi %>% filter(Quarter == 2) %>% pull(mean_ChlorA)

t.test(chl_q2, chl_q1, alternative = "greater")

```

```

##
##  Welch Two Sample t-test
##
## data:  chl_q2 and chl_q1
## t = 14.733, df = 7851.9, p-value < 2.2e-16
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:

```



```
## 0.2908823      Inf
## sample estimates:
## mean of x mean of y
## 0.7177111 0.3902679
```

- Hipótesis espacial:
 - H_0 : La media de oxígeno disuelto es igual en estaciones costeras y oceánicas.
 - H_1 : La media de oxígeno disuelto difiere entre zonas costeras y oceánicas (por influencia de surgencias).
- Hipótesis ecológica:
 - H_0 : La salinidad promedio en una región no difiere del rango histórico reportado.
 - H_1 : La salinidad promedio se ha desplazado fuera del rango histórico (posible cambio climático o anomalía oceanográfica).

6. MODELO DE REGRESIÓN

A continuación discutiremos uno de los modelos más influyentes en la matemática aplicada y en la estadística moderna: el modelo de regresión. Como bien recordaba George Box, “all models are wrong but some are useful”, y la regresión lineal es un claro ejemplo de ello: aunque simplifica la realidad, sigue siendo una herramienta poderosa para describir y analizar relaciones entre variables.

Comenzaremos presentando el modelo de regresión lineal simple, que permite cuantificar la asociación entre una variable dependiente y una independiente, para posteriormente avanzar hacia su extensión natural a múltiples predictores, es decir, la regresión múltiple.

6.1. Regresión lineal simple. El modelo de regresión lineal simple establece una relación matemática entre una variable dependiente Y y una variable independiente X , bajo la forma

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

El objetivo es estimar los parámetros β_0 (intercepto) y β_1 (pendiente) mediante el método de mínimos cuadrados ordinarios, que minimiza la suma de los errores al cuadrado. En notación matricial, el estimador se expresa como

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y},$$

garantizando la mejor aproximación lineal a los datos bajo los supuestos del modelo. En este caso, $\mathbf{X}$ es la matriz de diseño que incluye una columna de unos (para el intercepto) y otra columnas para la variable independiente, mientras que $\mathbf{Y}$ es el vector de observaciones de la variable dependiente.

La interpretación es directa: β_1 representa el cambio promedio en Y_i por cada unidad de incremento en X_i , mientras que β_0 corresponde al valor esperado de Y_i cuando $X_i = 0$.

Para que las inferencias del modelo lineal sean válidas, se formulan supuestos sobre los errores teóricos ε_i : que en promedio sean cero, que tengan varianza constante (homocedasticidad), que sean independientes y que sigan una distribución aproximadamente normal.

Estos supuestos no se observan directamente, pero tras ajustar el modelo podemos inspeccionar los residuos $r_i = Y_i - \hat{Y}_i$ como aproximaciones empíricas de los errores y evaluar si su comportamiento es consistente con lo esperado.

Cuando los residuos muestran patrones sistemáticos, heterocedasticidad o desviaciones severas de la normalidad, las pruebas de significancia y los intervalos de confianza derivados del modelo pueden

volverse poco confiables. En este sentido, la regresión lineal es una herramienta poderosa pero no infalible: como recordaba George Box, “all models are wrong but some are useful”, y su utilidad depende de cuán razonable sea asumir que los supuestos se cumplen en el contexto de los datos analizados

6.1.1. Herramientas de diagnóstico. De manera práctica, conviene echar mano de las siguientes consideraciones para realizar un chequeo empírico de los supuestos principales del modelo de regresión: los errores se han supuesto normales y heteroscedásticos.

6.1.1.1. Gráfico de residuos frente a valores ajustados (*predicidos*):

- **Definición:** representa los residuos del modelo en función de los valores ajustados.
- **Comportamiento esperado en residuos adecuados:** los puntos deben distribuirse de manera aleatoria alrededor de la línea horizontal en cero, sin mostrar patrones sistemáticos ni variaciones crecientes o decrecientes en la dispersión.
- **Interpretación:** la presencia de curvaturas sugiere una relación no lineal entre las variables; un patrón en forma de abanico indica heterocedasticidad, es decir, varianza no constante de los errores.

6.1.1.2. QQ-plot (gráfico cuantil-cuantil):

- **Definición teórica:** gráfico que compara los cuantiles de los residuos con los cuantiles de una distribución normal estándar, permitiendo evaluar la hipótesis de normalidad. Recuerda que para una variable aleatoria X , el cuantil de orden q se define como:

$$x_q = \inf\{x \in \mathbb{R} : F(x) \geq q\},$$

en donde F denota la distribución acumulada de la variable aleatoria. En el caso de una distribución normal estándar, los cuantiles se obtienen de la función inversa de la distribución normal, es decir, $x_q = \Phi^{-1}(q)$.

- **Comportamiento esperado en la práctica:** los puntos deben alinearse aproximadamente sobre la diagonal de referencia; desviaciones sistemáticas en los extremos reflejan colas más pesadas o más ligeras que las de la distribución normal.
- **Interpretación:** un alineamiento cercano a la recta indica que el supuesto de normalidad de los errores es razonable, condición necesaria para la validez de pruebas de significancia e intervalos de confianza.

6.1.1.3. Distancia de Cook.

- **Definición:** medida que cuantifica la influencia de cada observación sobre el ajuste del modelo, combinando el efecto del leverage (posición extrema en el espacio de predictores) con el tamaño del residuo. Se define como:

$$D_i = \frac{r_i^2}{p} \frac{h_{ii}}{(1 - h_{ii})^2},$$

donde r_i es el residuo de la observación i , p es el número de parámetros estimados en el modelo y h_{ii} es el elemento diagonal de la matriz sombrero ($H = X(X^T X)^{-1} X^T$).

- **Interpretación:** valores elevados de la distancia de Cook señalan observaciones que modifican sustancialmente los coeficientes estimados si se eliminan del análisis. Una regla práctica es considerar influyentes aquellas observaciones con $D_i > 4/n$, donde n es el tamaño de la muestra.
- **Relevancia:** permite distinguir entre puntos simplemente extremos y aquellos que ejercen una influencia significativa sobre el modelo, siendo una herramienta esencial para garantizar la robustez de las conclusiones.

6.1.2. *Hipótesis sobre la pendiente del modelo de regresión.* En el modelo lineal simple nos interesa probar si la pendiente β_1 es estadísticamente distinta de cero. En términos de *símbolos* de hipótesis:

- $H_0 : \beta_1 = 0$ (no hay relación lineal entre X e Y)
- $H_1 : \beta_1 \neq 0$ (sí existe relación lineal entre X e Y)

Bajo los supuestos del modelo, el estadístico de prueba está definido como:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)},$$

donde $SE(\hat{\beta}_1)$ denota el error estándar del estimador. Bajo H_0 , t tiene una distribución t -Student con $n - 2$ grados de libertad.

Por completitud, recordamos que el intervalo de confianza a nivel $1 - \alpha$ es:

$$\hat{\beta}_1 \pm t_{1-\alpha/2, n-2} SE(\hat{\beta}_1).$$

6.1.3. *Coefficiente de determinación.* En el modelo de regresión lineal simple, podemos cuantificar la variabilidad total de la respuesta Y mediante la suma de cuadrados total:

$$SS_{total} = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

Esta variabilidad se puede descomponer en dos componentes: la variabilidad explicada por el modelo y la variabilidad residual, es decir,

$$SS_{total} = SS_{reg} + SS_{res},$$

donde $SS_{reg} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ y $SS_{res} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$.

SS_{reg} representa la variabilidad de Y que es explicada por el modelo, mientras que SS_{res} refleja la variabilidad que no es capturada por el modelo (variabilidad residual).

El coeficiente de determinación se define como:

$$R^2 = \frac{SS_{reg}}{SS_{total}} = 1 - \frac{SS_{res}}{SS_{total}}.$$

De modo tal que R^2 cuantifica la proporción de la variabilidad total de Y que es capturada por la relación lineal con X . En regresión simple, bajo mínimos cuadrados ordinarios, se cumple además la identidad:

$$R^2 = r_{XY}^2,$$

donde r_{XY} es el coeficiente de correlación de Pearson entre X e Y . Un valor de R^2 cercano a 0 indica que el modelo apenas explica la variabilidad de la respuesta; un valor cercano a 1 indica que la recta de regresión explica gran parte de dicha variabilidad.

6.2. Modelo de regresión lineal múltiple. Utilizando algunas ideas presentadas en la sección anterior, podemos extender el modelo de regresión lineal simple a múltiples predictores. En esta sección discutiremos la estimación de los parámetros del modelo, así como las herramientas de diagnóstico y de inferencia estadística relacionadas a este modelo.

6.2.1. Estimación de parámetros.

- Definición: Extiende el modelo lineal simple a varios predictores:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i,$$

- Método de estimación: El vector de coeficientes $\hat{\beta}$ se obtiene mediante mínimos cuadrados ordinarios (OLS):

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y},$$

- Interpretación: Cada β_j refleja el cambio en Y por unidad de X_j con los demás predictores constantes; es decir, es el efecto parcial de X_j sobre la respuesta, controlando por las demás variables del modelo.

6.2.2. Diagnóstico del modelo.

- Gráficos de residuos: Se pueden generar gráficos de residuos frente a valores ajustados y QQ-plots para evaluar la normalidad y homocedasticidad de los errores.
- Distancia de Cook: Se puede calcular para identificar observaciones influyentes que puedan afectar significativamente los coeficientes estimados.
- Multicolinealidad: Se puede evaluar mediante el factor de inflación de la varianza (VIF) para detectar correlaciones altas entre predictores. A saber,

$$VIF_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación de la regresión de X_j sobre los demás predictores. Brevemente, para calcular R_j^2 , para cada predictor X_j en un modelo de regresión múltiple, se procede de la siguiente manera:

1. Se ajusta una **regresión auxiliar** donde X_j es la variable dependiente y todos los demás predictores son las variables explicativas:

$$X_j = \gamma_0 + \gamma_1 X_1 + \dots + \gamma_{j-1} X_{j-1} + \gamma_{j+1} X_{j+1} + \dots + \gamma_p X_p + u_j.$$

2. Se calcula el coeficiente de determinación de esta regresión auxiliar:

$$R_j^2 = 1 - \frac{\sum_{i=1}^n (X_{ji} - \hat{X}_{ji})^2}{\sum_{i=1}^n (X_{ji} - \bar{X}_j)^2},$$

donde $\hat{X}_{ji}$ son los valores ajustados de X_j y $\bar{X}_j$ es la media de X_j .

Un valor alto de R_j^2 implica que X_j puede ser explicado en gran medida por los demás predictores, lo que genera un VIF_j elevado y evidencia problemas de multicolinealidad.

6.2.3. Inferencia estadística.

- Pruebas de hipótesis para cada coeficiente:
 - Hipótesis nula $H_0 : \beta_j = 0$ (el predictor X_j no tiene efecto sobre Y)
 - Estadístico de prueba:

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)},$$

con $n - p$ grados de libertad, donde p es el número de predictores.

- Si el valor $p < \alpha$, se concluye que el predictor X_j tiene un efecto significativo sobre Y .
- Intervalos de confianza: proporcionan el rango plausible de valores para cada β_j .

6.2.4. *Bondad de ajuste global.* Al igual que en el modelo de regresión lineal simple, la bondad de ajuste del modelo múltiple se mide a través del coeficiente de determinación.

En este caso, R^2 mide la proporción de la variabilidad total de Y que es explicada por el modelo lineal con todos los predictores incluidos. A diferencia del caso simple, aquí R^2 ya no coincide con el cuadrado de una correlación de Pearson, porque refleja el efecto combinado de múltiples variables. Un valor cercano a 0 indica que el modelo apenas explica la variabilidad de la respuesta; un valor cercano a 1 indica que el conjunto de predictores explica gran parte de dicha variabilidad.

Esta medida de bondad de ajuste suele complementarse con la prueba F global, que evalúa la hipótesis nula de que todos los coeficientes de regresión (excepto el intercepto) son iguales a cero. Es decir,

$$\blacksquare H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$$

(ningún predictor contribuye significativamente al modelo).

- H_1 : Al menos un $\beta_j \neq 0$ (al menos un predictor tiene efecto significativo).

Para esta prueba, el estadístico se construye mediante la relación entre la variabilidad explicada por el modelo y la variabilidad residual, y se compara con una distribución F con p y $n - p - 1$ grados de libertad. Un valor p pequeño indica que al menos uno de los predictores tiene un efecto significativo sobre la variable dependiente. Para ser más precisos,

$$F = \frac{(SS_{reg}/p)}{(SS_{res}/(n - p - 1))},$$

Bajo H_0 , el estadístico F sigue una distribución F con p y $n - p - 1$ grados de libertad.

La prueba F es esencial porque ofrece una evaluación global del modelo: determina si el conjunto completo de predictores, considerados simultáneamente, explica una proporción significativa de la variabilidad de la respuesta. De este modo, funciona como un contraste inicial que valida la utilidad del modelo en su conjunto.

REFERENCIAS

- Casella, George, and Roger L. Berger. 2002. *Statistical Inference*. 2nd ed. Duxbury.
- Dikta, Gerhard, and Marsel Scheer. 2022. *Bootstrap Methods: With Applications in r*. Springer International Publishing. <https://doi.org/10.1007/978-3-030-73483-1>.
- Lee Rodgers, Joseph, and W Alan Nicewander. 1988. “Thirteen Ways to Look at the Correlation Coefficient.” *The American Statistician* 42 (1): 59–66.
- Wasserman, Larry. 2004. *All of Statistics: A Concise Course in Statistical Inference*. Springer. <https://doi.org/10.1007/978-0-387-21736-9>.