

R E I A PARA LA ENSEÑANZA DEL ANÁLISIS DE DATOS

NOTAS COMPLEMENTARIAS

INDER TECUAPETLA


1. BOXPLOT

Un boxplot está compuesto por:

- **Caja (box):** representa el rango intercuartílico (IQR), es decir, el 50 % central de los datos (del cuartil 1 al cuartil 3).
- **Línea dentro de la caja:** es la mediana (el valor central).
- **Bigotes (whiskers):** se extienden hasta los valores más extremos que aún se consideran “normales” (generalmente hasta $1.5 \times \text{IQR}$ desde los cuartiles).
- **Puntos fuera de los bigotes:** son los valores atípicos (outliers).

```
datos <- data.frame(temp = c(15,16,16,17,17,18,18,19,20,28))

ggplot(datos, aes(x = "", y = temp)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Ejemplo de boxplot con outlier",
       y = "Temperatura (°C)") +
  theme_minimal()
```



En este ejemplo tenemos:

- Mediana (Q2): valor central $\rightarrow 17.5$
- Q1 (25 %): 16.5

- Q3 (75 %): 18.5
- IQR (Q3 – Q1): 2
- Bigotes:
 - Límite inferior: $Q1 - 1.5 \times IQR = 16.5 - 3 = 13.5$
 - Límite superior: $Q3 + 1.5 \times IQR = 18.5 + 3 = 21.5$
 - Todo lo que esté fuera de 13.5–21.5 se considera outlier; el valor 28 está fuera de rango por tanto es un **outlier**.

En el bottle dataset de CalCOFI tenemos el siguiente boxplot:

```
calcofi_oceanica <- calcofi %>% filter(Dist_cat == "Oceánica")

ggplot(calcofi_oceanica, aes(x = Dist_cat, y = mean_T_degC, fill = Dist_cat)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Temperatura en categoría Oceánica (outliers marcados)",
       x = "", y = "Temperatura (°C)") +
  theme_minimal()
```




FIGURA 1. Distribución de la temperatura del océano registrada en puntos a distancia Oceánica respecto de la línea de costa.

con las siguientes estadísticas asociadas:

```
summary(calcofi_oceanica$mean_T_degC)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   6.313  10.100  12.033  12.390  14.374  34.322
```

por lo que el IQR en este caso es 4.274. De este modo, los límites inferior y superior son 3.689 y 20.785, respectivamente. Así todo valor fuera de este rango se considerará un outlier.

2. CORRELACIÓN

La correlación mide cómo dos variables se mueven juntas. Si incrementos en una variable tienden a acompañarse de incrementos en otra, hablamos de correlación positiva; si incrementos en una se asocian con disminuciones en otra, es negativa. Véase Lee Rodgers and Nicewander (1988) para diferentes representaciones del mismo objeto estadístico.

Coeficiente de correlación:

- Rango: De -1 a 1.
- Relación (lineal) positiva perfecta: 1
- Relación (lineal) negativa perfecta: -1
- No hay relación lineal: 0

Tipos principales:

- Pearson (r): para variables continuas con relación lineal.
- Spearman (ρ): para datos ordinales o rangos.
- Point-biserial y Phi: para variables dicotómicas.

Precauciones:

- Correlación no es equivalente a causalidad: Dos variables pueden estar correlacionadas por un tercer factor (ej. clima afecta tanto temperatura como oxígeno).
- Distorsiones comunes:
 - Restricción de rango: reduce artificialmente la magnitud de la correlación.
 - Datos atípicos: pueden inflar o reducir la correlación.
 - Muestras pequeñas: generan coeficientes poco estables.

El siguiente ejemplo muestra datos sintéticos de temperatura y oxígeno


```
temp <- c(15,16,17,18,19,20)
ox    <- c(8.0,7.8,7.5,7.2,6.9,6.5)

cor(temp, ox, method = "pearson")
```

```
## [1] -0.9957939
```

La representación gráfica de la asociación entre estas variables es:

```
plot(temp, ox,
      main = "Relación entre temperatura y oxígeno",
      xlab = "Temperatura (°C)", ylab = "Oxígeno (ml/L)",
      pch = 19, col = "blue")
abline(lm(ox ~ temp), col = "red")
```



Por completitud incluimos definiciones formales del coeficiente de correlación.

2.1. Definición teórica (poblacional). Sea (X, Y) un par de variables aleatorias con medias μ_X , μ_Y y desviaciones estándar σ_X , σ_Y , respectivamente. La correlación **poblacional** se define como:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

donde

$$\text{Cov}(X, Y) = \mathbf{E}[(X - \mu_X)(Y - \mu_Y)].$$

Es decir, la correlación es la covarianza normalizada por las desviaciones estándar.

2.2. Definición muestral (estimador). Dado un conjunto de observaciones (x_i, y_i) , con $i = 1, \dots, n$, la correlación muestral de Pearson se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde $\bar{x}$, $\bar{y}$ son las medias muestrales de X e Y , respectivamente.

3. INTERVALO DE CONFIANZA PARA LA MEDIA

Un intervalo de confianza (IC) es un rango de valores calculado a partir de una muestra que, con cierta probabilidad (nivel de confianza), contiene el verdadero valor del parámetro poblacional, Casella and Berger (2002), Wasserman (2004).

- El nivel de confianza más usado es 95 %, aunque también se emplean 90 % o 99 %.
- El IC refleja la incertidumbre inherente al muestreo: no garantiza que el parámetro esté dentro del intervalo, sino que en repeticiones del procedimiento, el porcentaje especificado de intervalos incluiría el valor verdadero.

Fundamentos teóricos

Frecuentista: El IC se interpreta en términos de repeticiones hipotéticas del muestreo.

Bayesiano: Se habla de intervalos de credibilidad, que tienen una interpretación probabilística directa sobre el parámetro.

Elementos clave:

- Estimador puntual ($\bar{x}$, proporción, etc.).
- Error estándar del estimador.
- Valor crítico de la distribución (t -Student, normal estándar, etc.).
- Margen de error = valor crítico $\times$ error estándar.

Algunas propiedades

- Precisión: Intervalos más estrechos indican mayor precisión.
- Dependencia del tamaño de muestra: A mayor n , menor error estándar y más estrecho el IC.
- Supuestos: Normalidad de los datos (o del estimador, vía teorema central del límite), independencia de observaciones.
- Limitaciones: En muestras grandes, cualquier desviación de normalidad puede invalidar el IC clásico; en distribuciones sesgadas, conviene usar bootstrap o transformaciones, Dikta and Scheer (2022).

4. ¿QUÉ ES UNA PRUEBA DE HIPÓTESIS?

Una prueba de hipótesis es un procedimiento estadístico que nos permite evaluar si la evidencia en una muestra es consistente con una afirmación sobre la población.

- Hipótesis nula (H_0): representa la condición de referencia, estabilidad o ausencia de efecto.
- Hipótesis alternativa (H_1): representa el cambio, diferencia o efecto que queremos detectar.

4.1. Elementos clave.

- Planteamiento de la hipótesis:
 - Ejemplo ambiental: La concentración promedio de nitratos en las aguas monitoreadas por CalCOFI se encuentra por debajo del umbral de preocupación ambiental de 16 μM
 - H_0 = “Promedio de nitratos es igual a 16 μM ”.
 - H_1 = “Promedio de nitratos es menor a 16 μM ”.
- Estadístico de prueba: Se calcula a partir de los datos (ej. t -estadístico). Resume la evidencia contra H_0 .
 - Ejemplo ambiental: Suponiendo que las observaciones de nitratos son independientes y aproximadamente normales con media μ y desviación estándar σ , entonces se sabe que

$$\bar{X}_n \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

por tanto

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Sin embargo, no conocemos el valor de σ , por lo que usamos la desviación estándar muestral s y el estadístico de prueba se convierte en

$$t = \frac{\bar{X}_n - \mu}{s/\sqrt{n}}$$

- Distribución de reference: **Bajo H_0** , el estadístico sigue una distribución conocida (ej. t -Student). Esto permite calcular probabilidades.
 - Ejemplo ambiental: Si H_0 es cierta, entonces el estadístico t sigue una distribución t -Student con $n - 1$ grados de libertad.
- p -valor: **Probabilidad** de obtener un resultado tan extremo como el observado, si H_0 fuera cierta. Si es pequeño (ej. < 0.05), se considera evidencia contra H_0 .
 - Ejemplo ambiental: En este caso, nos interesa calcular la probabilidad de observar un valor de t tan bajo como el calculado, dado que la media poblacional es $16 \mu\text{M}$. Si este p -valor es menor a 0.05 , rechazamos H_0 . Es decir, necesitamos calcular

$$p = P(t \leq t_{\text{obs}} \mid H_0),$$

donde t_{obs} es el valor calculado del estadístico de prueba.

- Decisión:
 - Rechazar $H_0 \rightarrow$ hay evidencia de que el promedio de nitratos es menor que el valor nominal ($16 \mu\text{M}$).
 - No rechazar $H_0 \rightarrow$ no hay evidencia suficiente para afirmar que el promedio de nitratos es menor que el valor nominal ($16 \mu\text{M}$).

5. PRUEBAS DE HIPÓTESIS EN CONTEXTO AMBIENTAL

Una prueba de hipótesis no es solo un cálculo mecánico: debe estar anclada en una pregunta científica o ambiental. En lugar de comparar contra un valor arbitrario (ej. $2 \text{ mg}/\text{m}^3$), podemos formular hipótesis basadas en condiciones ecológicas, estacionales o espaciales.

5.1. Ejemplos de hipótesis contextualizadas.

- Hipótesis espacial:
 - H_0 : La media de nitratos en zona superficial es igual a la media en zona profunda.
 - H_1 : La media de nitratos en zona superficial difiere de la media en zona profunda (posible efecto de surgencias).

En este caso el estadístico de prueba podría ser un t -test para muestras independientes, comparando las medias de nitratos en ambas zonas. Más específicamente, si $X_1, X_2, \dots, X_n$ son las concentraciones de nitratos en la zona superficial y $Y_1, Y_2, \dots, Y_m$ en la zona profunda, entonces el estadístico sería:

$$t = \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}}$$

y se sabe que los grados de libertad aproximados se calculan mediante la fórmula de Welch-Satterthwaite:

$$df \approx \frac{\left(\frac{s_X^2}{n} + \frac{s_Y^2}{m}\right)^2}{\frac{(s_X^2/n)^2}{n-1} + \frac{(s_Y^2/m)^2}{m-1}}.$$

Operativamente, tenemos:

```
# Extraer los datos por zona de profundidad
nitrate_surface <- calcofi %>%
  filter(Depth_zone == "Surface") %>%
  pull(mean_Nitrate)

nitrate_deep <- calcofi %>%
  filter(Depth_zone == "Deep") %>%
  pull(mean_Nitrate)

mean_surface <- mean(nitrate_surface, na.rm = TRUE)
mean_deep <- mean(nitrate_deep, na.rm = TRUE)

sd_surface <- sd(nitrate_surface, na.rm = TRUE)
sd_deep <- sd(nitrate_deep, na.rm = TRUE)

n_surface <- length(na.omit(nitrate_surface))
n_deep <- length(na.omit(nitrate_deep))

se <- sqrt( (sd_surface^2 / n_surface) + (sd_deep^2 / n_deep) )

t_stat <- (mean_surface - mean_deep) / se

df <- ( (sd_surface^2/n_surface + sd_deep^2/n_deep)^2 ) /
  ( ((sd_surface^2/n_surface)^2 / (n_surface-1)) +
    ((sd_deep^2/n_deep)^2 / (n_deep-1)) )

p_val <- 2 * (1 - pt(abs(t_stat), df))

list(
  mean_surface = mean_surface,
  mean_deep = mean_deep,
  t_statistic = t_stat,
  df = df,
  p_value = p_val
)
```

```
# Two-sample t-test (bilateral)
resultado <- t.test(nitrate_surface, nitrate_deep, alternative = "two.sided")

# Mostrar el p-value directamente
resultado$p.value
```

- Hipótesis estacional:
 - H_0 : La media de clorofila en Quarter 2 es igual a la de Quarter 1.
 - H_1 : La media de clorofila en Quarter 2 es mayor (esperando un pico de productividad en primavera).

```
chl_q1 <- calcofi %>% filter(Quarter == 1) %>% pull(mean_ChlorA)
chl_q2 <- calcofi %>% filter(Quarter == 2) %>% pull(mean_ChlorA)

t.test(chl_q2, chl_q1, alternative = "greater")
```

```
##
## Welch Two Sample t-test
##
## data: chl_q2 and chl_q1
## t = 14.733, df = 7851.9, p-value < 2.2e-16
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
## 0.2908823 Inf
## sample estimates:
## mean of x mean of y
## 0.7177111 0.3902679
```

- Hipótesis espacial:
 - H_0 : La media de oxígeno disuelto es igual en estaciones costeras y oceánicas.
 - H_1 : La media de oxígeno disuelto difiere entre zonas costeras y oceánicas (por influencia de surgencias).
- Hipótesis ecológica:
 - H_0 : La salinidad promedio en una región no difiere del rango histórico reportado.
 - H_1 : La salinidad promedio se ha desplazado fuera del rango histórico (posible cambio climático o anomalía oceanográfica).

6. MODELO DE REGRESIÓN

A continuación discutiremos uno de los modelos más influyentes en la matemática aplicada y en la estadística moderna: el modelo de regresión. Como bien recordaba George Box, “all models are wrong but some are useful”, y la regresión lineal es un claro ejemplo de ello: aunque simplifica la realidad, sigue siendo una herramienta poderosa para describir y analizar relaciones entre variables.

Comenzaremos presentando el modelo de regresión lineal simple, que permite cuantificar la asociación entre una variable dependiente y una independiente, para posteriormente avanzar hacia su extensión natural a múltiples predictores, es decir, la regresión múltiple.

6.1. Regresión lineal simple. El modelo de regresión lineal simple establece una relación matemática entre una variable dependiente Y y una variable independiente X , bajo la forma

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

El objetivo es estimar los parámetros β_0 (intercepto) y β_1 (pendiente) mediante el método de mínimos cuadrados ordinarios, que minimiza la suma de los errores al cuadrado. En notación matricial, el estimador se expresa como

$$\hat{\beta} = (X^\top X)^{-1} X^\top Y,$$

garantizando la mejor aproximación lineal a los datos bajo los supuestos del modelo.

La interpretación es directa: β_1 representa el cambio promedio en Y por cada unidad de incremento en X , mientras que β_0 corresponde al valor esperado de Y cuando $X = 0$.

Para que las inferencias del modelo lineal sean válidas, se formulan supuestos sobre los errores teóricos ε_i : que en promedio sean cero, que tengan varianza constante (homocedasticidad), que sean independientes y que sigan una distribución aproximadamente normal.

Estos supuestos no se observan directamente, pero tras ajustar el modelo podemos inspeccionar los residuos $r_i = Y_i - \hat{Y}_i$ como aproximaciones empíricas de los errores y evaluar si su comportamiento es consistente con lo esperado.

Cuando los residuos muestran patrones sistemáticos, heterocedasticidad o desviaciones severas de la normalidad, las pruebas de significancia y los intervalos de confianza derivados del modelo pueden volverse poco confiables. En este sentido, la regresión lineal es una herramienta poderosa pero no infalible: como recordaba George Box, “all models are wrong but some are useful”, y su utilidad depende de cuán razonable sea asumir que los supuestos se cumplen en el contexto de los datos analizados.

6.2. Herramientas de diagnóstico. De manera práctica, conviene echar mano de las siguientes consideraciones para realizar un chequeo empírico de los supuestos principales del modelo de regresión: los errores se han supuesto normales y heteroscedásticos.

6.2.1. Gráfico de residuos frente a valores ajustados (predecidos):

- **Definición:** representa los residuos del modelo en función de los valores ajustados.
- **Comportamiento esperado en residuos adecuados:** los puntos deben distribuirse de manera aleatoria alrededor de la línea horizontal en cero, sin mostrar patrones sistemáticos ni variaciones crecientes o decrecientes en la dispersión.
- **Interpretación:** la presencia de curvaturas sugiere una relación no lineal entre las variables; un patrón en forma de abanico indica heterocedasticidad, es decir, varianza no constante de los errores.

6.2.2. QQ-plot (gráfico cuantil-cuantil):

- **Definición teórica:** gráfico que compara los cuantiles de los residuos con los cuantiles de una distribución normal estándar, permitiendo evaluar la hipótesis de normalidad. Recuerda que para una variable aleatoria X , el cuantil de orden q se define como:

$$x_q = \inf\{x \in \mathbb{R} : F(x) \geq q\},$$

en donde F denota la distribución acumulada de la variable aleatoria. En el caso de una distribución normal estándar, los cuantiles se obtienen de la función inversa de la distribución normal, es decir, $x_q = \Phi^{-1}(q)$.

- **Comportamiento esperado en la práctica:** los puntos deben alinearse aproximadamente sobre la diagonal de referencia; desviaciones sistemáticas en los extremos reflejan colas más pesadas o más ligeras que las de la distribución normal.
- **Interpretación:** un alineamiento cercano a la recta indica que el supuesto de normalidad de los errores es razonable, condición necesaria para la validez de pruebas de significancia e intervalos de confianza.

6.2.3. Distancia de Cook.

- **Definición:** medida que cuantifica la influencia de cada observación sobre el ajuste del modelo, combinando el efecto del leverage (posición extrema en el espacio de predictores) con el tamaño del residuo. Se define como:

$$D_i = \frac{r_i^2}{p} \frac{h_{ii}}{(1 - h_{ii})^2},$$

donde r_i es el residuo de la observación i , p es el número de parámetros estimados en el modelo y h_{ii} es el elemento diagonal de la matriz sombrero ($H = X(X^T X)^{-1} X^T$).

- **Interpretación:** valores elevados de la distancia de Cook señalan observaciones que modifican sustancialmente los coeficientes estimados si se eliminan del análisis. Una regla práctica es considerar influyentes aquellas observaciones con $D_i > 4/n$, donde n es el tamaño de la muestra.
- **Relevancia:** permite distinguir entre puntos simplemente extremos y aquellos que ejercen una influencia significativa sobre el modelo, siendo una herramienta esencial para garantizar la robustez de las conclusiones.

6.3. Hipótesis sobre la pendiente del modelo de regresión. En el modelo linear simple nos interesa probar si la pendiente β_1 es estadísticamente distinta de cero. En términos de *símbolos* de hipótesis:

- $H_0 : \beta_1 = 0$ (no hay relación lineal entre X e Y)
- $H_1 : \beta_1 \neq 0$ (sí existe relación lineal entre X e Y)

Bajo los supuestos del modelo, el estadístico de prueba está definido como:

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)},$$

donde $SE(\hat{\beta}_1)$ denota el error estándar del estimador. Bajo H_0 , t tiene una distribución t -Student con $n - 2$ grados de libertad.

Por completitud, recordamos que el intervalo de confianza a nivel $1 - \alpha$ es:

$$\hat{\beta}_1 \pm t_{1-\alpha/2, n-2} SE(\hat{\beta}_1).$$

REFERENCIAS

- Casella, George, and Roger L. Berger. 2002. *Statistical Inference*. 2nd ed. Duxbury.
- Dikta, Gerhard, and Marsel Scheer. 2022. *Bootstrap Methods: With Applications in r*. Springer International Publishing. <https://doi.org/10.1007/978-3-030-73483-1>.
- Lee Rodgers, Joseph, and W Alan Nicewander. 1988. “Thirteen Ways to Look at the Correlation Coefficient.” *The American Statistician* 42 (1): 59–66.
- Wasserman, Larry. 2004. *All of Statistics: A Concise Course in Statistical Inference*. Springer. <https://doi.org/10.1007/978-0-387-21736-9>.