

R E I A PARA LA ENSEÑANZA DEL ANÁLISIS DE DATOS

NOTAS COMPLEMENTARIAS

INDER TECUAPETLA


1. BOXPLOT

Un boxplot está compuesto por:

- **Caja (box):** representa el rango intercuartílico (IQR), es decir, el 50 % central de los datos (del cuartil 1 al cuartil 3).
- **Línea dentro de la caja:** es la mediana (el valor central).
- **Bigotes (whiskers):** se extienden hasta los valores más extremos que aún se consideran “normales” (generalmente hasta $1.5 \times \text{IQR}$ desde los cuartiles).
- **Puntos fuera de los bigotes:** son los valores atípicos (outliers).

```
datos <- data.frame(temp = c(15,16,16,17,17,18,18,19,20,28))

ggplot(datos, aes(x = "", y = temp)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Ejemplo de boxplot con outlier",
       y = "Temperatura (°C)") +
  theme_minimal()
```



En este ejemplo tenemos:

- Mediana (Q2): valor central $\rightarrow 17.5$
- Q1 (25 %): 16.5

- Q3 (75 %): 18.5
- IQR (Q3 – Q1): 2
- Bigotes:
 - Límite inferior: $Q1 - 1.5 \times IQR = 16.5 - 3 = 13.5$
 - Límite superior: $Q3 + 1.5 \times IQR = 18.5 + 3 = 21.5$
 - Todo lo que esté fuera de 13.5–21.5 se considera outlier; el valor 28 está fuera de rango por tanto es un **outlier**.

En el bottle dataset de CalCOFI tenemos el siguiente boxplot:

```
calcofi_oceanica <- calcofi %>% filter(Dist_cat == "Oceánica")

ggplot(calcofi_oceanica, aes(x = Dist_cat, y = mean_T_degC, fill = Dist_cat)) +
  geom_boxplot(outlier.color = "red", outlier.shape = 8) +
  labs(title = "Temperatura en categoría Oceánica (outliers marcados)",
       x = "", y = "Temperatura (°C)") +
  theme_minimal()
```




FIGURA 1. Distribución de la temperatura del océano registrada en puntos a distancia Oceánica respecto de la línea de costa.

con las siguientes estadísticas asociadas:

```
summary(calcofi_oceanica$mean_T_degC)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   6.313  10.100  12.033  12.390  14.374  34.322
```

por lo que el IQR en este caso es 4.274. De este modo, los límites inferior y superior son 3.689 y 20.785, respectivamente. Así todo valor fuera de este rango se considerará un outlier.

2. CORRELACIÓN

La correlación mide cómo dos variables se mueven juntas. Si incrementos en una variable tienden a acompañarse de incrementos en otra, hablamos de correlación positiva; si incrementos en una se asocian con disminuciones en otra, es negativa. Véase Lee Rodgers and Nicewander (1988) para diferentes representaciones del mismo objeto estadístico.

Coeficiente de correlación:

- Rango: De -1 a 1.
- Relación (lineal) positiva perfecta: 1
- Relación (lineal) negativa perfecta: -1
- No hay relación lineal: 0

Tipos principales:

- Pearson (r): para variables continuas con relación lineal.
- Spearman (ρ): para datos ordinales o rangos.
- Point-biserial y Phi: para variables dicotómicas.

Precauciones:

- Correlación no es equivalente a causalidad: Dos variables pueden estar correlacionadas por un tercer factor (ej. clima afecta tanto temperatura como oxígeno).
- Distorsiones comunes:
 - Restricción de rango: reduce artificialmente la magnitud de la correlación.
 - Datos atípicos: pueden inflar o reducir la correlación.
 - Muestras pequeñas: generan coeficientes poco estables.

El siguiente ejemplo muestra datos sintéticos de temperatura y oxígeno


```
temp <- c(15,16,17,18,19,20)
ox    <- c(8.0,7.8,7.5,7.2,6.9,6.5)

cor(temp, ox, method = "pearson")
```

```
## [1] -0.9957939
```

La representación gráfica de la asociación entre estas variables es:

```
plot(temp, ox,
      main = "Relación entre temperatura y oxígeno",
      xlab = "Temperatura (°C)", ylab = "Oxígeno (ml/L)",
      pch = 19, col = "blue")
abline(lm(ox ~ temp), col = "red")
```



Por completitud incluimos definiciones formales del coeficiente de correlación.

2.1. Definición teórica (poblacional). Sea (X, Y) un par de variables aleatorias con medias μ_X , μ_Y y desviaciones estándar σ_X , σ_Y , respectivamente. La correlación **poblacional** se define como:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y},$$

donde

$$\text{Cov}(X, Y) = \mathbf{E}[(X - \mu_X)(Y - \mu_Y)].$$

Es decir, la correlación es la covarianza normalizada por las desviaciones estándar.

2.2. Definición muestral (estimador). Dado un conjunto de observaciones (x_i, y_i) , con $i = 1, \dots, n$, la correlación muestral de Pearson se calcula como:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

donde $\bar{x}$, $\bar{y}$ son las medias muestrales de X e Y , respectivamente.

REFERENCIAS

Lee Rodgers, Joseph, and W Alan Nicewander. 1988. “Thirteen Ways to Look at the Correlation Coefficient.” *The American Statistician* 42 (1): 59–66.